INFORME

Práctica 9 - Diseño de experimentos

Alumnas: Julieta Barahona Roth, Mia Bertola y Valentina Calzetta

1. Pregunta
¿Cuántos servidores hacen falta para mantener bajo el P95 según la carga, y cuál de los dos factores afecta más al resultado?

2. Hipótesis
Con 1 servidor el sistema se satura y el P95 crece mucho. A partir de 2 servidores el P95 casi no depende de la carga.

3. Diseño experimental

Elemento	**Definición**
Factores	Cantidad de servidores y carga (cantidad de solicitudes)
Niveles	Servidores: 1, 2 y 4. Carga: 500, 1000 y 2000
Respuesta	P95 de la latencia, promedio de las réplicas
Réplicas	10 por combinación, con semilla 1000 + n. réplica
Escenario base	2 servidores y carga 1000
Matriz	3!=9 combinaciones, 90 corridas

Usamos las mismas semillas en todas las combinaciones. Así las diferencias que aparecen vienen del factor que cambiamos y no del azar.

4. Matriz factorial
P95 medio de las 10 réplicas (entre paréntesis y desvío).

Servidores	**Carga 500**	**Carga 1000**	**Carga 2000**
1	520,03 (58,45)	1053,98 (119,38)	2206,37 (169,68)
2	12,91 (1,40)	13,57 (1,50)	14,33 (1,03)
4	7,30 (0,34)	7,43 (0,26)	7,59 (0,10)

5. Efecto de cada factor

- Servidores (carga fija en 1000): pasar de 1 a 2 baja el P95 de 1053,98 a 13,57, y de 2 a 4 lo baja a 7,43.
- Carga (2 servidores fijos): de 500 a 2000 el P95 solo sube de 12,91 a 14,33.

El desvío con 2 y 4 servidores es chico (1,5 como máximo), por eso consideramos que 10 réplicas alcanzan para comparar.

6. Desafío:

Como cambio estructural cambiamos la política de la cola: un servidor queda dedicado solo a las solicitudes de prioridad alta y el resto atiende las normales. Es estructural porque cambia cómo se reparten las solicitudes entre los servidores, no solo un número. Lo comparamos contra la cola FIFO compartida con carga 1000.

Servidores	**Política**	**P95 alta**	**P95 normal / general**
2	FIFO compartida	15,64	13,57 (general)
2	Servidor dedicado	16,41	128,93 (normales)
4	FIFO compartida	9,48	7,43 (general)
4	Servidor dedicado	16,41	6,42 (normales)

Con 2 servidores las normales quedan con un solo servidor y se saturan. Con 4 las normales mejoran un poco, pero las altas empeoran casi al doble, porque un único servidor tiene que atender las solicitudes más largas.

7. Interpretación

La hipótesis se cumplió y lo que observamos es que la cantidad de servidores es lo que más pesa, y que la carga casi no cambia nada con 2 o 4 servidores. Esto pasa porque en generar_logs la carga es la cantidad de solicitudes, pero llegan siempre a la misma tasa (una cada 3 en promedio). Más carga significa más tiempo simulado, no solicitudes más seguidas. Con 1 servidor el tiempo de atención medio (cerca de 4) es mayor que el tiempo entre llegadas, entonces la cola nunca se vacía y el P95 crece casi proporcional a la carga.

8. Recomendación condicionada

- 1 servidor no sirve para ninguna carga.
- Si el SLA acepta un P95 de alrededor de 15, alcanza con 2 servidores.
- Si se exige un P95 menor a 10, hacen falta 4.
- Para priorizar de verdad habría que cambiar el simulador para que, cuando se libera un servidor, elija primero la solicitud alta que esté esperando.

9. Limitaciones

Las limitaciones que tenemos es que la tasa de llegada siempre es la misma, la cola es FIFO y los tiempos de atención salen de la misma distribución. Para estudiar más demanda real habría que variar cada cuánto llegan las solicitudes y no solo la cantidad.

10. Conclusiones

El diseño factorial permite ver el efecto de cada factor por separado y que el que manda es la cantidad de servidores. También aprendimos que hay que revisar qué representa cada factor en el modelo, porque la carga como estaba definida no medía lo que esperábamos.