Informe Práctica 10: Análisis de sensibilidad

1. Problema y pregunta

El equipo no sabe qué parámetros afectan más la latencia del sistema. La pregunta es: **¿qué variable mueve más el P95, a partir de qué valores el sistema deja de ser aceptable y cuánto cambia el efecto de una variable según el valor de otra?**

2. Supuestos y rangos justificados

- Un único conjunto base de 1.000 solicitudes (generar_logs(1000), semilla 2026), que mantiene llegadas y prioridades en todos los escenarios.
- **Factor de servicio: 0,70 a 1,30** en pasos de 0,15. Es el rango que propone el manual (+-30 % del tiempo de servicio) y representa una mejora o un empeoramiento realista.
- **Servidores: 1 a 4.** Es el rango del enunciado; un servidor es el mínimo posible y cuatro ya deja el sistema holgado.
- Referencia de calidad: **P95 < 10**.
- Caso base: factor 1,00 y 2 servidores.
- La cantidad de servidores se usa como aproximación del costo de capacidad (más servidores, más costo).

3. Resultados

Sensibilidad uno por vez (2 servidores)

Factor de servicio	0,70	0,85	1,00	1,15	1,30
P95	6,84	9,34	14,39	23,77	45,18
Utilización	0,48	0,58	0,69	0,79	0,89

P95 por servidores y factor de servicio

Servidores	0,70	0,85	1,00	1,15	1,30
1	89,08	499,26	1087,29	1677,86	2270,93
2	6,84	9,34	14,39	23,77	45,18
3	5,38	6,71	8,31	9,90	11,96
4	5,22	6,33	7,45	8,72	10,01

Umbrales y no linealidades

- **No linealidad:** con 2 servidores, cada aumento de 0,15 en el factor suma más P95 que el anterior: +2,5, +5,05, +9,38 y +21,41. El efecto casi se duplica en cada paso. Ocurre porque la utilización se acerca a 1 (de 0,48 a 0,89) y las colas crecen de forma acelerada.
- **Umbral de 2 servidores:** el P95 pasa de 10 entre los factores 0,85 y 1,00.
- **Umbral de 3 servidores:** aguanta hasta el factor 1,15 (9,90) y supera 10 en 1,30.
- **Umbral de 4 servidores:** queda en el límite recién en 1,30 (10,01).
- **Saturación con 1 servidor:** la utilización llega a 1,0 y el P95 supera 1.000. Con el tráfico de este conjunto, un servidor no alcanza en ningún escenario.

Diagrama tornado (caso base: P95 = 14,39)

Variable (rango)	Variación del P95
Factor de servicio (0,85 a 1,15)	14,43
Servidores (2 a 3)	6,08
Semilla de los datos (2026 a 2030)	2,00

La semilla mide el ruido: con otros datos generados igual, el P95 base se mueve unos 2 puntos (entre 12,39 y 14,39).

Interacción

El efecto de pasar el factor de 0,70 a 1,30 depende de los servidores: +38,34 con 2 servidores, +6,58 con 3 y +4,79 con 4. Si no hubiera interacción, el efecto sería igual en todos los casos. Hay una interacción fuerte: el tiempo de servicio importa mucho cuando hay pocos servidores y poco cuando hay capacidad de sobra.

4. Desafío adicional: cambio estructural

Cambio: en lugar de un pool único de servidores, uno queda dedicado a las solicitudes de prioridad alta (202 de 1.000) y el resto atiende las normales. El modelo pasa de una cola con varios servidores a dos colas independientes, y la latencia total se arma juntando las latencias de ambas.

Servidores totales	P95 pool único	P95 separado	P95 alta (dedicado)	P95 normal
2	14,39	121,12	16,80	123,21
3	8,31	10,54	16,80	8,22
4	7,45	9,60	16,80	6,44

Recomendación condicionada: si no existe un requisito de aislar la prioridad alta, conviene mantener el pool único: con 2 servidores separar satura la cola normal, y con 3 el P95 supera la referencia de 10. Solo valdría separar si el negocio exige garantías específicas para prioridad alta. Esta comparación no midió el P95 de la prioridad alta dentro del pool, así que no se puede afirmar cuánto mejora o empeora esa clase en particular.

5. Interpretación

1. **¿Qué decisión apoya?** Cuántos servidores mantener y cuánto margen de variación del tiempo de servicio tolera el sistema. Para cumplir P95 < 10: 2 servidores toleran hasta un factor de 0,85, 3 servidores hasta 1,15 y 4 servidores casi hasta 1,30.
2. **¿Qué variable condiciona más?** En el rango razonable, el factor de servicio (variación 14,43) pesa más que agregar un servidor (6,08) y mucho más que el ruido de los datos (2,00). Pero el factor más determinante es la utilización: con 1 servidor se satura y todo lo demás deja de importar. Las otras variables actúan a través de ella.
3. **¿Cómo se verificó?** Se usó siempre el mismo conjunto base. La fila de 2 servidores de la tabla coincide con los resultados del primer bucle (14,39 en el factor 1,00) y con la semilla 2026 del tornado. El P95 crece al subir el factor y baja al sumar servidores en todas las filas y columnas. Y la utilización con 2 servidores (0,69) coincide con lo esperado: servicio medio de unas 4,1 unidades, llegadas cada 3 unidades en promedio y 2 servidores dan 4,1 / (3 * 2) ~ 0,69.
4. **¿Qué cambió respecto de la expectativa inicial?** Esperaba que el P95 creciera de forma más o menos proporcional al tiempo de servicio, y que un servidor extra diera una mejora parecida en cualquier situación. El efecto resultó fuertemente no lineal: pasar de 1,15 a 1,30 agrega 21,41, casi nueve veces lo que agrega pasar de 0,70 a 0,85 (2,5). Además, el valor de agregar un servidor depende de cuánta carga hay.
5. **¿Hasta dónde se generalizan las conclusiones?** Solo para este tipo de tráfico (llegadas y servicios del generador del laboratorio), con 1.000 solicitudes, cola FIFO y los rangos probados. Diferencias de P95 menores a unos 2 puntos no se pueden distinguir del ruido entre conjuntos de datos.

5. Limitaciones

- El "costo" no se modeló: solo se usó la cantidad de servidores como aproximación.
- El ruido se estimó con 5 semillas; es una referencia, no un intervalo de confianza.
- El análisis es por escenarios (uno por vez y una grilla), no un diseño de experimentos completo con réplicas.
- El desafío solo comparó la latencia total y la de cada cola; no incluyó el P95 de la prioridad alta dentro del pool.