

INFORME

Práctica 1 · Reconocimiento y modelización de un sistema

Alumnas: Julieta Barahona Roth, Mia Bertola y Valentina Calzetta

1. Ficha del problema y destinatarios

Situación: una plataforma de turnos presenta demoras variables, quiere decir que algunas personas en horas pico, esperan más del percentil establecido (se colapsa el sistema).

Pregunta de modelización: ¿Con 2 o 3 servidores la plataforma mantiene el P95 de demora por debajo de 15 minutos incluyendo la hora pico?

Decisión que apoya: Cuántos servidores debo tener disponibles en un horario normal y en horario pico.

Destinatarios:

- Responsable de la plataforma: decide la capacidad y presupuesto
- Equipo técnico: implementa y monitorea los servidores
- Usuarios que solicitan turnos: son los afectados
- Alcance: se estudia el recorrido de una solicitud desde que llega hasta que se le asigna el turno.

2. Diagrama del sistema

FRONTERA → llegada del usuario, cola, servidores y salida del mismo.

ENTORNO → usuarios, horarios pico, red y servicio de notificaciones.

3. Tabla de variables, parámetros y supuestos

Elemento	Tipo	Valor	Origen
Llegadas de solicitudes	Entrada	En promedio 1 cada 3 min, al azar (exponencial)	Datos sintéticos del laboratorio (generar_logs)
Proporción de prioridad alta	Parámetro	20 %	Datos sintéticos del laboratorio

Tiempo de atención	Parámetro	Variable: 3,5<tiempo<5,5 min	Datos sintéticos del laboratorio
Cantidad de servidores	Variable de decisión	2 sería la base o 3 el refuerzo en hora pico	Alternativas a evaluar
Intensidad del pico	Variable de escenario	Llegadas 30% más juntas (factor 0,7)	Supuesto
Solicitudes en cola y servidores ocupados	Estado	Cambian durante la simulación	Resultado del modelo
Demora promedio, P95 y utilización	Salidas	Se miden en cada corrida	Resultado del modelo
Objetivo de servicio	Criterio de decisión	$P95 \leq 15 \text{ min}$	Supuesto

Supuestos del modelo

1. Las solicitudes llegan de forma independiente
2. Cada solicitud se atiende completa, sin interrupciones ni fallas del servidor.
3. Se atiende con cola FIFO y sin límite.
4. Las solicitudes de prioridad alta (20%) tardan más en atenderse que las normales.

Condiciones del experimento: 200 solicitudes por corrida, 5 réplicas por escenario, semillas 2026 a 2030. Las mismas semillas se usan en todos los escenarios, para que las diferencias se deban a lo que cambia y no al azar.

4. Tres escenarios

Cada escenario cambia una sola condición respecto del anterior:

Escenario	Demanda	Servidores	Qué cambia
BASE	Normal	2	Situación actual
HORA PICO	30% más	2	La demanda
REFUERZO	30% más	3	La capacidad

5. Verificación: caso con 1 servidor y valores fijos, calculado a mano:

Solicitud	Llega	Empieza	Termina	Demora
1	0	0	3	3
2	1	3	5	4
3	2	5	6	4

**Tiempo medido en minutos*

El simulador devolvió exactamente [3, 4, 4]. Esto verifica que el código hace lo que definimos.

6. Resultados: promedio de 5 réplicas de 200 solicitudes cada una:

Escenario	P95
BASE	14,1 min
PICO	36,3 min
REFUERZO	10,4 min

7. Interpretación

2 servidores alcanzan, pero muy en el borde porque el P95 está muy cerca del límite de 15 min entonces con un 30% más de demanda, el sistema va a desbordarse porque el margen es muy justo, los servidores quedan casi todo el tiempo ocupados y la cola se acumula. En cambio con 3 servidores se vuelve a cumplir el margen P95 de 10,4 min, para la hora pico.

8. Desafío: cambio estructural

En el nuevo escenario pasamos en vez de 2 servidores y una sola cola compartida, elegimos cambiar a dos colas separadas: 1 servidor exclusivo para prioridad alta y 1 servidor exclusivo para las normales. No cambiamos el número de servidores tuvimos que separar las solicitudes por prioridad y simular dos colas independientes.

Resultados (demanda normal, 5 réplicas):

Configuración	P95 prioridad alta	P95 prioridad normal
Cola compartida (base)	15,6 min	13,4 min
Servidor exclusivo por prioridad	16,5 min	53,9 min

Al final separar los servidores no ayuda como nos esperábamos, el servidor de las normales queda casi saturado ya que recibe el 80% de la demanda y se le limitó a la mitad la capacidad, mientras que el de las altas queda muchas veces sin trabajar y trabajar con dos colas diferentes no permite que se puedan compensar. Con la cola compartida, cualquier servidor libre atiende al siguiente, así que la capacidad se aprovecha mejor.

9. Recomendación condicionada

En horario normal: mantener 2 servidores con una cola compartida, siempre que la demanda no crezca. Como el P95 está cerca del límite hay que tener cuidado.

En hora pico (demanda 30% mayor o más): pasar a 3 servidores.

Señal para pasar a 3 servidores: si el P95 medido se acerca a 15 minutos.

10. Limitaciones

- Los datos son sintéticos
- Los resultados son un escenario hipotético, no una predicción.
- El modelo no incluye fallas de servidores, reintentos ni límite de cola
- El pico se representó juntando las llegadas un 30%; un pico real puede tener otra forma (por ejemplo, ráfagas cortas).