

INFORME

Práctica 3 - Logs, variabilidad y datos sintéticos

Alumnas: Julieta Barahona Roth, Mia Bertola y Valentina Calzetta

1. Pregunta

¿Qué valores conviene usar para simular la plataforma de turnos, y qué pasa con esos valores si los logs vienen con errores?

2. Perfil de calidad

Se revisaron los 1000 registros buscando faltantes, valores inválidos y duplicados. No se encontró ningún problema.

Es esperable: los datos son sintéticos. Los logs reales casi nunca son así de limpios

3. Medidas del tiempo de atención

Grupo	n	Media	Mediana	Desvío	P95	P99
Todos	1000	4,16	3,79	1,78	7,42	10,09
Alta	202	5,84	5,40	2,34	10,09	
Normal	798	3,74	3,55	1,29	6,08	

**Tiempo medido en minutos.*

La media es mayor que la mediana: hay algunas atenciones largas que hacen crecer el promedio para arriba. Alta y normal son dos grupos distintos: las altas tardan más y varían más.

4. Parámetros justificados

Conviene modelar las prioridades por separado porque si se usara un único valor, las altas quedarían subestimadas.

Parámetro	Valor	Justificación
-----------	-------	---------------

Tiempo entre llegadas	3,02 min en promedio (tasa $\approx$ 0,33 por min)	Calculado de los logs. Media $\approx$ desvío (3,02 y 2,96), que es lo típico de llegadas al azar (exponencial)
Atención normal	Mediana 3,55 min	Calculado de los logs, por separado
Atención alta	Mediana 5,40 min	Calculado de los logs, por separado
Proporción alta	20,2%	Calculado de los logs
Forma del tiempo de atención	Asimétrica (lognormal)	Media > mediana y cola hacia valores altos

5. Desafío

El cambio es estructural porque el modelo necesita una etapa nueva de limpieza con reglas explícitas: descartar faltantes, valores ≤ 0 o > 60 min, y duplicados por id.

Los logs pasan a tener errores de registro (2% faltantes, 2% negativos, 2% valores multiplicados por 100 y 2% duplicados).

Datos	n	Media	Mediana	Desvío	P95
Originales	1000	4,16	3,79	1,78	7,42
Con errores, sin limpiar	1000	13,56	3,79	73,92	7,94
Con errores, limpios	940	4,14	3,77	1,76	7,35

Pocos errores (8%) triplican la media y multiplican el desvío por 40.

6. Recomendación condicionada

- Si los logs se pueden limpiar se tiene que usar media, mediana y percentiles.

- Si no se pueden limpiar, tenemos que usar mediana y percentiles, no la media ni el desvío

7. Supuestos y limitaciones

- datos sintéticos
- límite de 60 min es un supuesto y una atención más larga se toma como un error de registro
- los errores del desafío son inventados
- asume que alta y normal no cambian con el horario.

8. Conclusiones

Llegamos a la conclusión que alta y normal deben parametrizarse por separado porque cada turno tardan distintos tiempos y en la simulación las solicitudes de prioridad alta se atenderían más rápido de lo que se atienden en realidad. No podemos poner todos los tiempos de turno de todos los pacientes en la misma bolsa. (Error de usar promedios)