

Informe breve - Práctica 5: Colas, capacidad y rendimiento

Alumno/equipo: Bertola, Barahona Roth y Calzetta **Fecha:** 30/09/2026

1. Objetivo

En esta práctica analizamos cómo influye la cantidad de servidores en el rendimiento de un sistema con cola. Comparamos tres configuraciones: 1, 2 y 4 servidores. El objetivo fue medir la latencia promedio, los percentiles P95 y P99, el throughput y la utilización para poder recomendar una capacidad adecuada.

2. Modelo y supuestos

Simulamos 1500 solicitudes con una semilla fija (2026). De esta forma, las tres configuraciones recibieron exactamente las mismas llegadas y tiempos de servicio, por lo que la comparación es equivalente.

El modelo supone que:

- Las solicitudes se atienden con una única cola FIFO: se atienden por orden de llegada.
 - Cada solicitud se asigna al primer servidor que queda libre.
 - Los tiempos entre llegadas son variables y los tiempos de servicio también presentan variabilidad.
 - El sistema tiene 1, 2 o 4 servidores idénticos.
 - No se consideran caídas, abandonos de cola, prioridades efectivas ni cambios de demanda durante la ejecución.
-

3. Resultados

Servidores	Latencia promedio	P95	P99	Throughput	Utilización
1	929.88	1727.48	1785.71	0.2399	99.91 %
2	6.12	12.15	16.94	0.3365	70.09 %
4	4.20	7.54	10.37	0.3368	35.07 %

La tabla completa en formato CSV se encuentra en `resultados/tabla_comparativa.csv`.

4. Interpretación de los resultados

Con un solo servidor, el sistema queda prácticamente saturado: su utilización es de 99.91 %. Como consecuencia, se forma una cola muy grande y la latencia promedio llega a 929.88 unidades de tiempo. Los valores P95 y P99 también son muy altos, lo que indica que gran parte de las solicitudes experimenta demoras importantes.

Al pasar a dos servidores, el comportamiento cambia de forma marcada. La latencia promedio baja a 6.12 y el P95 a 12.15. Además, el throughput aumenta a 0.3365 y la utilización se mantiene en un valor razonable de 70.09 %. Esto muestra que dos servidores pueden atender la demanda sin que la cola crezca de forma sostenida.

Con cuatro servidores se obtienen los mejores valores de latencia: el P95 baja a 7.54 y el P99 a 10.37. Sin embargo, el throughput casi no cambia respecto del caso de dos servidores, mientras que la utilización de cada servidor baja a 35.07 %. Por lo tanto, se incorporan recursos que permanecen ociosos durante una parte importante de la simulación.

5. Recomendación

Recomendaríamos utilizar **2 servidores** como configuración base. Esta alternativa elimina la saturación observada con un servidor, reduce fuertemente la latencia y mantiene una utilización aceptable de los recursos.

La configuración de 4 servidores podría justificarse si el sistema tuviera un acuerdo de nivel de servicio muy exigente, por ejemplo un límite de P95 menor a 10 unidades de tiempo, o si se esperaran picos de demanda mayores a los simulados. En las condiciones analizadas, el beneficio adicional de pasar de 2 a 4 servidores es menor que el beneficio obtenido al pasar de 1 a 2.

6. Respuestas para interpretar

¿Qué decisión puede apoyarse con esta práctica?

Esta práctica permite decidir cuántos servidores conviene asignar al sistema para evitar saturación y demoras excesivas, sin sobredimensionar la capacidad.

¿Qué variable o supuesto condiciona más el resultado?

La relación entre la tasa de llegada de solicitudes y el tiempo de servicio condiciona fuertemente el resultado. Con un solo servidor, la capacidad disponible no alcanza para absorber la demanda y la cola crece rápidamente.

¿Cómo verificamos que la implementación representa lo definido?

Verificamos que las tres configuraciones usaran el mismo conjunto de 1500 solicitudes y la misma semilla. También comprobamos que cada solicitud se asignara al primer servidor disponible y que las métricas se calcularan a partir de las latencias obtenidas en la simulación.

¿Qué resultado cambió respecto de nuestra expectativa inicial y por qué?

Nos llamó la atención que pasar de 2 a 4 servidores casi no modificara el throughput. Esto ocurre porque, con dos servidores, la capacidad ya es suficiente para atender la demanda; por eso los servidores adicionales mejoran la latencia, pero no aumentan significativamente la cantidad de solicitudes completadas por unidad de tiempo.

¿Hasta dónde pueden generalizarse las conclusiones?

Las conclusiones son válidas para los parámetros, la distribución de llegadas y los tiempos de servicio utilizados en esta simulación. Antes de aplicarlas a un sistema real sería necesario validar el modelo con datos reales, incorporar costos y simular picos de demanda, fallas y prioridades.

7. Limitaciones

El modelo simplifica el comportamiento real del sistema. No considera interrupciones, fallas de servidores, tiempos de red, abandonos de usuarios, variaciones horarias de demanda ni costos de infraestructura. Por este motivo, la recomendación debe tomarse como una primera aproximación y no como una decisión definitiva sin validar con datos reales.