

# Informe breve - Práctica 6:

## Latencia, throughput y acuerdos de servicio

---

**Alumno/equipo:** Bertola, Barahona Roth y Calzetta **Fecha:** 30/09/2026

### 1. Objetivo

---

En esta práctica evaluamos el cumplimiento de un acuerdo de nivel de servicio (SLA) para distintos escenarios de carga. Analizamos la latencia, el throughput y la tasa de errores para determinar si dos servidores alcanzan y para proponer un plan de capacidad cuando el SLA no se cumple.

### 2. Definición del SLA y supuestos

---

Definimos el SLA con las siguientes condiciones:

- El percentil 95 de latencia (P95) debe ser menor a 10 unidades de tiempo.
- La tasa de errores debe ser menor o igual a 1 %.
- Se considera error a una solicitud cuya latencia supera las 15 unidades de tiempo, porque en ese punto representa un timeout del servicio.

Simulamos una cola FIFO con servidores idénticos. La simulación utiliza una semilla fija para que los resultados sean reproducibles. Los escenarios fueron baja, media y alta carga; el factor de demanda modifica el intervalo entre llegadas: a mayor factor, las solicitudes llegan

con más frecuencia.

No consideramos fallas de infraestructura, reintentos, cambios de prioridad durante la cola, costos de los servidores ni variaciones de la demanda dentro de un mismo escenario.

### 3. Resultados con 2 servidores

---

| Escenario | Solicitudes | P95     | P99     | Throughput | Utilización |
|-----------|-------------|---------|---------|------------|-------------|
| Baja      | 500         | 9.14    | 10.91   | 0.260      | 54.01 %     |
| Media     | 1000        | 12.18   | 15.74   | 0.314      | 65.19 %     |
| Alta      | 2000        | 1143.58 | 1194.29 | 0.481      | 99.89 %     |

Las tablas completas están disponibles en `resultados/evaluacion_sla.csv`, `resultados/comparacion_capacidad.csv` y `resultados/plan_capacidad.csv`.

La tabla `comparacion_capacidad.csv` incluye la comparación de 1 a 8 servidores para cada escenario. De este modo, la recomendación no se basa solo en una configuración: se elige la menor cantidad de servidores que cumple las dos condiciones del SLA.

### 4. Análisis de incumplimientos

---

El escenario de carga baja cumple el SLA con dos servidores: el P95 es 9.14 y no aparecen timeouts. Por lo tanto, la capacidad actual es suficiente para esta demanda.

En carga media, el sistema no cumple porque el P95 sube a 12.18 y la tasa de errores llega a 1.30 %. Aunque el throughput continúa siendo adecuado, hay una parte de las solicitudes que supera el timeout. Esto

muestra que mejorar solamente el throughput no garantiza cumplir el SLA de latencia.

En carga alta se observa una saturación clara. La utilización llega a 99.90 %, el P95 supera ampliamente el límite y casi todas las solicitudes superan el timeout. En este caso, la capacidad actual no puede absorber la intensidad de llegada y la cola crece de manera sostenida.

## 5. Plan de capacidad

---

| Escenario | Capacidad mínima recomendada | P95 con capacidad recomendada | Tasa de errores |
|-----------|------------------------------|-------------------------------|-----------------|
| Baja      | 2 servidores                 | 9.14                          | 0.00 %          |
| Media     | 3 servidores                 | 7.97                          | 0.00 %          |
| Alta      | 4 servidores                 | 8.70                          | 0.00 %          |

Recomendaríamos mantener 2 servidores para el escenario de carga baja, escalar a 3 servidores cuando se alcance la demanda media y disponer de 4 servidores para los períodos de carga alta. Este plan permite cumplir el SLA sin mantener cuatro servidores activos cuando la demanda es baja.

## 6. Respuestas para interpretar

---

### ¿Qué decisión puede apoyarse con esta práctica?

Esta práctica permite definir un plan de capacidad: la cantidad de servidores que se necesita para cumplir los objetivos de latencia y errores en cada nivel de demanda.

### ¿Qué variable o supuesto condiciona más el resultado?

La intensidad de las llegadas condiciona más el resultado. Cuando las solicitudes llegan con demasiada frecuencia respecto de la capacidad disponible, la cola crece y aumenta tanto la latencia como la tasa de timeouts.

## **¿Cómo verificamos que la implementación representa lo definido?**

Verificamos que el programa calcule el P95 sobre todas las latencias simuladas y que clasifique como error únicamente a las solicitudes que superan el umbral de timeout definido. También ejecutamos los tres escenarios con una semilla fija y comprobamos que el plan de capacidad busque la menor cantidad de servidores que cumple las dos condiciones del SLA.

## **¿Qué resultado cambió respecto de nuestra expectativa inicial y por qué?**

El resultado que más nos llamó la atención fue que, en carga media, el throughput siguiera siendo razonable aunque el SLA ya no se cumpliera. Esto muestra que completar muchas solicitudes no implica necesariamente que los usuarios reciban una respuesta dentro del tiempo esperado.

## **¿Hasta dónde pueden generalizarse las conclusiones?**

Las conclusiones aplican a las distribuciones, umbrales y niveles de carga utilizados en esta simulación. Para llevarlas a un sistema real habría que validar el modelo con logs reales e incorporar costos, fallas, picos horarios, reintentos y prioridades.

## **7. Limitaciones**

---

El modelo es una simplificación. En particular, el timeout se representa

solo por la latencia simulada y no incluye errores reales de aplicación o red. Además, todos los servidores se consideran iguales y siempre disponibles. Por eso, el plan propuesto debe validarse antes de aplicarlo a producción.