INFORME

Práctica 12 - Predicción de demanda

Alumnas: Mia Bertola, Julieta Barahona Roth y Valentina Calzetta

1. Problema y objetivo

En esta práctica construimos un predictor sencillo de demanda y lo comparamos con una referencia básica. Retomamos el contexto de las prácticas anteriores, en las que analizamos solicitudes, colas y capacidad de atención. En este caso nos concentramos en anticipar la demanda, como paso previo a una futura decisión de capacidad.

La pregunta que nos planteamos fue: ¿podemos mejorar la predicción de los próximos instantes si aprendemos la tendencia de los datos anteriores, en lugar de repetir el último valor observado?

Para responderla, implementamos una regresión lineal y un baseline, respetando el orden temporal de los datos. Primero estudiamos una serie reproducible; después ampliamos la comparación a cien semillas y, finalmente, analizamos un cambio repentino y permanente de demanda. Obtuvimos menor error con la regresión en los casos evaluados, aunque comprobamos que ambos métodos pierden precisión cuando aparece un cambio que no observaron durante el entrenamiento.

2. Datos y supuestos

Generamos cien observaciones sintéticas mediante la fórmula del manual:

```
demanda(t) = 100 + 4*t + 25*sin(t/3) + ruido
```

Usamos ruido con distribución normal, media cero y desvío estándar de ocho unidades. Por lo tanto, no generamos valores totalmente aleatorios dentro de un rango fijo: combinamos una tendencia creciente, una oscilación y variaciones aleatorias.

Trabajamos con unidades abstractas de tiempo y demanda. No identificamos cada instante con una hora o un día real. Aunque la situación del manual menciona hora, día y actividad reciente, seguimos su plantilla mínima y usamos únicamente el tiempo como variable explicativa.

Usamos la semilla 2026 para el caso principal. Conservamos la fórmula del manual, pero generamos el ruido con el generador de Python. Por eso reproducimos nuestros resultados localmente, aunque los valores no son idénticos a los del generador JavaScript integrado en el HTML.

Separamos la serie de la siguiente manera:

Conjunto	Instantes	Cantidad	Uso
Entrenamiento	0 a 79	80	Ajustar la recta y obtener el último valor observado
Prueba	80 a 99	20	Evaluar las predicciones

Mantuvimos el orden temporal y no mezclamos los datos. Ajustamos los modelos usando solamente el entrenamiento y reservamos el conjunto de prueba para medir el error. Pronosticamos los veinte pasos desde el mismo punto de partida, sin actualizar los métodos con los valores que aparecen durante la prueba.

3. Métodos y medición del error

Construimos el baseline repitiendo el último valor del entrenamiento para los veinte instantes siguientes. Elegimos esta referencia porque representa una decisión sencilla: suponer que la demanda futura se mantendrá en el último nivel observado. Así pudimos evaluar si ajustar

una recta aportaba una mejora frente a ese criterio.

Para la regresión lineal ajustamos la relación:

```
demanda estimada(t) = intercepto + pendiente*t
```

Calculamos el intercepto y la pendiente por mínimos cuadrados, minimizando la suma de los errores al cuadrado sobre los ochenta datos de entrenamiento. Después extendimos la recta a los instantes 80 a 99.

Evaluamos ambos métodos con el error absoluto medio, o MAE:

```
MAE = suma de |demanda real − demanda predicha| / cantida
```

Interpretamos esta medida en unidades de demanda. Por ejemplo, un MAE de 20 indica que las predicciones se apartan, en promedio, veinte unidades de los valores reales. Al tomar valores absolutos, evitamos que los errores positivos y negativos se cancelen. Comparamos ambos métodos sobre los mismos datos de prueba para mantener una evaluación equivalente.

4. Caso base con semilla fija

Primero usamos una única serie con semilla 2026 para comprobar el procedimiento y contar con un caso que pudiéramos repetir. Obtuvimos un último valor de entrenamiento de 441,50 unidades, que mantuvimos como predicción constante del baseline.

Con la regresión obtuvimos la siguiente recta, mostrando los coeficientes redondeados:

```
demanda estimada(t) = 103,2514 + 3,9074*t
```

Estimamos así un aumento de aproximadamente 3,91 unidades por instante. Usamos los coeficientes sin redondear para calcular las predicciones y los errores.

Método	MAE sobre los veinte datos de prueba
Baseline constante	25,31
Regresión lineal	18,77

Obtuvimos una reducción del error promedio de aproximadamente el 25,84 % respecto del baseline. Interpretamos esta mejora a partir de la tendencia creciente de la serie: con la recta pudimos representar ese crecimiento, mientras que con el baseline mantuvimos un único nivel de demanda.

No eliminamos el error porque con una recta no representamos explícitamente las oscilaciones ni el ruido. Tampoco interpretamos este resultado como una mejora garantizada en cada instante: comparamos el error promedio de todo el horizonte.

Repetimos la evaluación cinco veces con la misma semilla y obtuvimos exactamente los mismos datos y resultados. Con esto comprobamos la reproducibilidad, pero no agregamos cinco escenarios diferentes: al fijar la semilla repetimos la misma realización del ruido.

5. Comparación entre distintas semillas

Decidimos ampliar el análisis porque una sola serie podía favorecer a un método por la realización particular del ruido. Para comprobar si la ventaja se mantenía, evaluamos cien semillas consecutivas, desde 2026 hasta 2125.

En cada réplica generamos una nueva serie de cien datos, volvimos a ajustar la regresión con los primeros ochenta y evaluamos ambos métodos con los últimos veinte. Dentro de cada réplica usamos exactamente la misma serie para los dos métodos. Conservamos la fórmula, el nivel de ruido y el corte temporal; modificamos únicamente la semilla.

Indicador entre las cien réplicas	Baseline	Regresión
MAE promedio	26,81	17,49

Desvío muestral de los MAE	4,26	1,67
Menor MAE observado	20,50	12,81
Mayor MAE observado	43,82	21,74
Réplicas con menor MAE que el otro método	0	100

Obtuvimos menor MAE con la regresión en las cien réplicas, sin empates. Calculamos una reducción del MAE promedio del 34,77 % mediante:

```
100 * (1 − MAE promedio de regresión / MAE promedio de ba
```

Calculamos este porcentaje a partir de los promedios sin redondear; no promediamos los porcentajes de mejora individuales.

Además de reducir el error, obtuvimos menor dispersión de los MAE con la regresión. Interpretamos que su desempeño fue más estable frente a los ruidos evaluados. Con el baseline dependimos de una sola observación para fijar todas las predicciones; con la regresión estimamos la tendencia a partir del conjunto de entrenamiento.

Con esta comparación reunimos evidencia más amplia que con la semilla inicial. Sin embargo, seguimos estudiando el mismo patrón de demanda y el mismo horizonte. No usamos las cien semillas para elegir una corrida favorable ni para ajustar parámetros mirando el conjunto de prueba.

6. Desafío adicional con cambio de régimen

Decidimos estudiar un cambio de régimen porque variar las semillas solo modificaba el ruido. También queríamos observar qué ocurría cuando cambiaba una condición estructural que los modelos no habían visto.

Partimos de la serie con semilla 2026 y sumamos 150 unidades a cada observación desde el instante 80. Introdujimos así un salto permanente en el nivel de demanda justo al comenzar la prueba. Conservamos los

ochenta datos de entrenamiento y el ruido del caso base para aislar el efecto de ese salto.

Con este escenario representamos una posible situación de aumento repentino de actividad, sin afirmar que reproduzca un evento real. Modificamos la estructura temporal de la serie al introducir una discontinuidad; no cambiamos simplemente la semilla.

Escenario	MAE baseline	MAE regresión
Serie original con semilla 2026	25,31	18,77
Salto permanente de 150 unidades desde t = 80	165,92	154,46

Obtuvimos un aumento marcado del error con ambos métodos. Mantuvimos las mismas predicciones del caso base porque el entrenamiento no cambió y ninguno de los modelos recibió información anticipada sobre el salto. En este escenario subestimamos la demanda real con ambos métodos en todo el horizonte de prueba.

Nos llamó la atención que la regresión siguiera siendo la mejor de las dos alternativas y, al mismo tiempo, tuviera un error tan elevado. Con esto distinguimos dos preguntas: qué método funciona mejor que otro y si su precisión alcanza para una decisión concreta. No definimos un umbral operativo de aceptación, por lo que no podemos concluir que el menor MAE sea suficiente para planificar capacidad.

Si detectáramos un cambio semejante, recomendaríamos monitorear los errores, revisar los supuestos y actualizar el modelo con nuevas observaciones. No implementamos una adaptación automática en esta práctica.

7. Verificación y evidencia

Comprobamos el cálculo de la regresión con una serie construida a partir de la recta exacta `demanda(t) = 7 + 3*t`. Recuperamos el intercepto 7 y la pendiente 3, y obtuvimos MAE cero al predecir su continuación. También comprobamos el MAE con un ejemplo manual.

Para revisar la separación temporal, modificamos únicamente los datos de prueba y comprobamos que no cambiaran el intercepto, la pendiente ni el valor usado por el baseline. Con esto verificamos que el ajuste no utilizara información futura. También comprobamos que el horizonte tuviera veinte predicciones y que repetir una semilla reprodujera la serie.

Guardamos la evidencia en la carpeta `resultados/`:

- En `serie_demanda.csv` registramos la serie principal y su partición temporal.
- En `predicciones.csv` guardamos los valores reales, ambas predicciones y sus errores.
- En `comparacion_100_semillas.csv` registramos los MAE y su diferencia para cada semilla.
- En `predicciones_cambio_regimen.csv` guardamos los resultados del desafío.
- En `resumen.json` conservamos los coeficientes, la configuración y los indicadores de los tres análisis.

Para regenerar los resultados ejecutamos desde la carpeta general del repositorio:

```
python3 "Práctica 12/practica_12_prediccion.py"
```

No necesitamos instalar librerías externas. Mantuvimos las semillas y las constantes de configuración en el código para poder repetir los experimentos.

8. Limitaciones y conclusiones

Trabajamos con datos sintéticos que contienen una tendencia creciente definida de antemano. Por eso limitamos nuestras conclusiones a esta fórmula, al ruido utilizado y al horizonte de veinte pasos. No comparamos otros cortes temporales, modelos con estacionalidad, redes neuronales ni variables de calendario. Tampoco calculamos intervalos de predicción ni evaluamos directamente costos o incumplimientos de servicio.

Entre los supuestos que estudiamos, consideramos especialmente

importante la continuidad del comportamiento entre entrenamiento y prueba: al romperla con el salto de demanda, obtuvimos errores mucho mayores. No comparamos exhaustivamente todos los parámetros, por lo que no afirmamos que este supuesto sea siempre el más influyente.

Concluimos que, para la serie estudiada, aprendimos una tendencia que permitió mejorar la predicción respecto de repetir el último valor observado. La mejora no quedó limitada a la semilla inicial: obtuvimos menor MAE con la regresión en las cien semillas y una reducción del MAE promedio del 34,77 %.

Elegimos los casos para responder preguntas diferentes. Con la semilla fija comprobamos el funcionamiento y la reproducibilidad; con las distintas semillas analizamos la dependencia respecto del ruido; con el cambio de régimen evaluamos el límite de extrapolar un comportamiento pasado. Así evitamos basar la conclusión únicamente en una corrida favorable.

Podríamos usar esta predicción como entrada para una futura evaluación de capacidad, pero todavía no determinamos cuántos servidores necesitaríamos. Para tomar esa decisión tendríamos que relacionar la demanda predicha con el simulador, establecer un margen de error aceptable y evaluar las consecuencias de subestimar la carga. Antes de aplicar el enfoque a una plataforma real, también necesitaríamos validarlo con registros observados.