Informe Práctica 14: Modelo híbrido

Integrantes: Bertola, Barahona y Calzetta

1. Problema y pregunta

Un predictor estima la demanda por hora y una regla decide cuántos servidores asignar. La pregunta es: **¿la cadena predictor → regla → simulación cumple con la latencia esperada (P95 < 10) y cómo se propaga el error del predictor hacia la decisión de capacidad?**

2. Arquitectura modular y contratos de datos

Módulo	Entrada	Salida (contrato)
Predictor predecir_demanda(hora)	hora (6, 9, 12, 15, 18, 21)	demanda numérica positiva; se convierte a entero
Regla decidir_capacidad(demanda)	demanda entera	servidores: 1 (< 700), 2 (< 850) o 4
Generador generar_logs(n, semilla)	demanda como cantidad y semilla	lista de **n** registros con **id**, **llegada** (ordenada), **servicio** > 0 y **prioridad**
Simulador simular_cola(datos, servidores)	logs y servidores	diccionario con **P95**, **latencias** (una por solicitud) y otras métricas
Error del predictor (Monte Carlo)	demanda prevista	demanda real = prevista * (1 + error), error triangular de −15 % a +15 %

Cada contrato se verifica en el código y los cuatro dan **True**. La regla propia coincide con decidir_servidores() del laboratorio.

3. Supuestos

- Demanda = cantidad de solicitudes del escenario; las llegadas y servicios salen del generador del laboratorio (una llegada cada 3 unidades en promedio, servicio medio de unas 4,1 unidades). La demanda alarga el escenario pero no acelera las llegadas.
- Semilla de cada franja: **2026 + hora**. Referencia de calidad: P95 < 10.
- Error del predictor: +-15 %, distribución triangular centrada en 0 (supuesto propio, sin datos históricos que lo respalden). 200 réplicas por franja.

- "Costo" medido como cantidad de servidores sumada en las 6 franjas.

4. Resultados

Modelo híbrido (regla original)

Hora	Demanda	Servidores	P95
6	600	1	600,56
9	677	1	831,16
12	859	4	7,41
15	889	4	7,71
18	750	2	11,92
21	600	1	693,22

Con 1 servidor el sistema se satura (carga estimada de 1,4 servidores ocupados en promedio) y el P95 llega a valores muy altos. La regla asigna 1 servidor justo cuando la demanda es menor a 700, que son 3 de las 6 franjas.

Propagación del error del predictor (200 réplicas por hora)

Hora	Demanda prevista	Servidores	Decisión distinta a la de la demanda real	P95 medio (decisión del predictor)	P95 medio (decisión de la demanda real)
6	600	1	0 %	659,4	659,4
9	677	1	29 %	743,6	514,5
12	859	4	45,5 %	7,6	10,4
15	889	4	27 %	7,6	9,3
18	750	2	14 %	13,9	117,0
21	600	1	0 %	658,1	658,1

Cómo se propaga: la regla es un escalón, así que el error solo importa cuando cruza un umbral (700 u 850). Cuanto más cerca está la predicción de un umbral, más veces cambia la decisión: a las 12 (859, a 9 del umbral de 850) cambia en 45,5 % de las réplicas; a las 6 y 21 (600, lejos de 700) nunca. El efecto tiene dos signos:

- **Subcapacidad (hora 9):** la predicción 677 queda justo debajo de 700. Si la demanda real es mayor, la regla habría puesto 2 servidores y no 1; el P95 medio con la decisión del predictor es 743,6 contra 514,5.
- **Sobrecapacidad (horas 12 y 15):** si la demanda real es menor, la regla habría usado 2 servidores; el predictor deja 4. El P95 es mejor (7,6), pero con 2 servidores extra en 27 a 45 % de los casos.

Comparación con el modelo base (2 servidores fijos)

Hora	Híbrido (servidores, P95)	Base (2 servidores, P95)
6	1, 600,56	12,07
9	1, 831,16	15,14
12	4, 7,41	14,02
15	4, 7,71	15,30
18	2, 11,92	11,92
21	1, 693,22	12,38

Servidores sumados: híbrido 13, base 12. El híbrido gana en las horas pico (P95 de 7,4 y 7,7 contra 14,0 y 15,3) pero pierde por mucho en las 3 franjas con 1 servidor.

5. Desafío adicional: cambio estructural

Cambio: la regla deja de depender solo de la demanda. Ahora la cantidad de servidores es el máximo entre la regla original y un mínimo calculado desde los logs: el trabajo total dividido el tiempo de llegadas da los servidores ocupados en promedio, y se exige una utilización de 0,6 como máximo. **Por qué cambia el modelo:** la regla necesita los logs antes de decidir, así que el orden de los módulos se invierte (se generan los datos y después se decide) y su contrato de entrada incorpora los logs.

Hora	Servidores (regla nueva)	P95
6	3	8,00
9	3	8,39
12	4	7,41
15	4	7,71
18	3	7,86
21	3	7,98

Servidores sumados: 20 (híbrido original: 13; base: 12). El P95 queda por debajo de 10 en todas las franjas. Con un límite de utilización de 0,8 la regla pondría 2 servidores (16 en total), evitaría la saturación pero daría P95 de 12 a 15 en 4 de las 6 franjas.

Recomendación condicionada: si el objetivo es P95 < 10 en todas las franjas, usar la regla nueva (límite de utilización 0,6) y aceptar unos 8 servidores más que el base. Si solo importa evitar la saturación y se tolera un P95 de 12 a 15, alcanza con 2 servidores mínimos. En ningún caso conviene mantener 1 servidor cuando la demanda es menor a 700.

6. Limitaciones

- La demanda solo define cuántas solicitudes se simulan, no la intensidad de llegadas.
- El error del predictor es un supuesto sin datos históricos de respaldo.
- La comparación "decisión de la demanda real" mide qué habría decidido la regla, no necesariamente la mejor capacidad posible.
- No se probaron 3 servidores en las horas pico (la regla usa 4 ahí).
- El costo se aproxima con la cantidad de servidores.